MỤC LỤC

TỔNG QUAN DỰ ÁN		2
1.	Mục tiêu dự án	2
2.	Mô hình dữ liệu (Star Schema)	2
3.	Xử lý thay đổi dữ liệu	2
4.	Kiến trúc Medallion	2
5.	Công nghệ & dịch vụ Azure	3
6.	Nguồn dữ liệu	3
CHUẨN BỊ HẠ TẦNG DEVELOPMENT		4
1.	Resource Group	4
2.	Storage Account	4
3.	Azure Databricks	5
4.	Service Principal	6
PIPELINE XỬ LÝ DỮ LIỆU		7
1.	Ingest (Bronze Layer)	7
2.	Transform (Silver Layer)	. 11
3.	Load (Gold Layer)	.17
CI/CD VÀ TỰ ĐỘNG HÓA25		
1.	Chuẩn bị hạ tầng Production	.25
2.	Kết nối Git với Workspace Dev	.27
3.	Thiết lập CI/CD Production	.28
4.	Tự động hóa Lịch Chạy Job	.28
5	Kết nối Power BI với Azure Databricks	29

TỔNG QUAN DỰ ÁN

1. Mục tiêu dự án

- > Tự động thu thập thông tin phim mới phát hành và phim đang thịnh hành mỗi tuần.
- ➤ Hỗ trợ người xem đưa ra gợi ý nhanh chóng, giúp lựa chọn phim phù hợp với thể loại yêu thích.

2. Mô hình dữ liệu (Star Schema)

- **❖** Bång Dimension
 - ♣ dim movie Thông tin phim (ID, tiêu đề, thời lượng...)
 - 4 dim genre Thể loại phim
 - ♣ dim company Công ty sản xuất
 - ♣ dim director Đạo diễn
 - ♣ dim date Tuần phân tích
- Bång Fact
 - ♣ fact_movies Ghi nhận lượt xem, đánh giá, tương tác, liên kết các bảng dimension

3. Xử lý thay đổi dữ liệu

- CDC (Change Data Capture): Chỉ ingest dữ liệu mới hoặc đã thay đổi dựa trên timestamp.
- > SCD (Slowly Changing Dimensions): Sử dụng Type 1 (ghi đè) để quản lý lịch sử dữ liệu dimension.

4. Kiến trúc Medallion

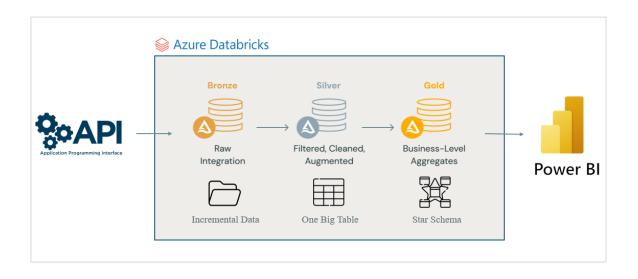
- Bronze Dữ liệu thô ingest trực tiếp từ API (phim mới, phim xu hướng, thể loại)
- o Silver Dữ liệu đã làm sạch, chuẩn hóa schema
- Gold: Dữ liệu tổng hợp, sẵn sàng cho báo cáo và trực quan hóa.

5. Công nghệ & dịch vụ Azure

- o Azure Data Lake Storage Gen2 Tao 3 container (bronze, silver, gold).
- Azure Databricks Sử dụng Delta Lake để lưu trữ, Databricks SQL để biến đổi.
- Quản lý bảo mật Service Principal để cấp quyền truy cập an toàn cho
 Databricks.
- CI/CD Sử dụng GitHub Actions để tự động deploy notebooks giữa môi trường Dev/Prod.

6. Nguồn dữ liệu

- ❖ The Movie Database (TMDB) API: https://www.themoviedb.org/
 - Cung cấp metadata phim: ngày phát hành, poster, lượt bình luận, điểm đánh giá...
 - Hỗ trợ truy vấn incremental theo ngày/tuần để tối ưu băng thông và thời gian xử lý.

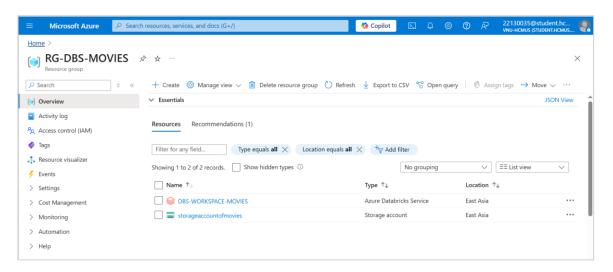


CHUẨN BỊ HẠ TẦNG DEVELOPMENT

Trước khi triển khai pipeline, chúng ta cần thiết lập đầy đủ các tài nguyên Azure để đảm bảo môi trường sẵn sàng cho việc phát triển và vận hành.

1. Resource Group

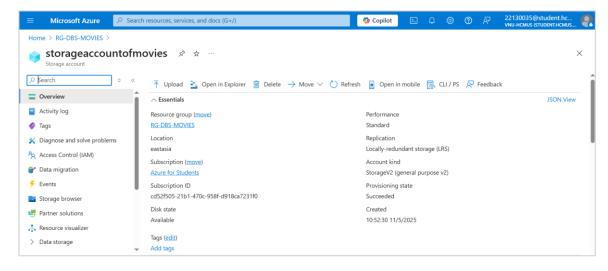
Tạo một Resource Group



Resource Group "RG-DBS-MOVIES" là vùng chứa tập trung các tài nguyên liên quan đến dự án, giúp chúng ta dễ dàng quản lý, theo dõi chi phí và quyền truy cập.

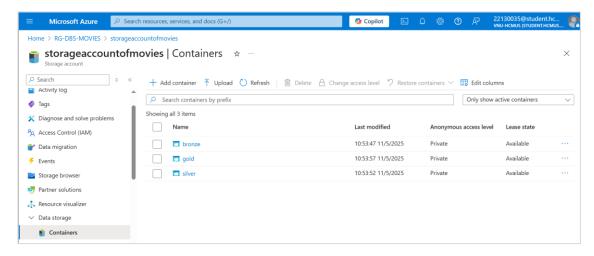
2. Storage Account

Tạo một Storage Account



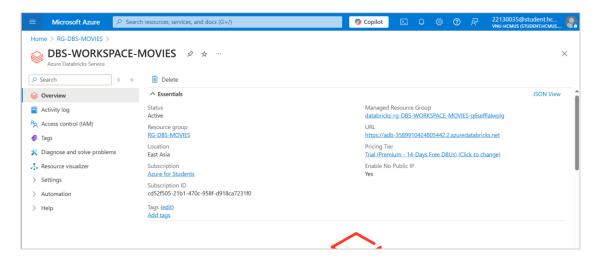
Storage Account "storageaccountofmovies" chịu trách nhiệm lưu trữ dữ liệu thô, trung gian và kết quả cuối cùng.

Tạo các Containers trong Data Lake



3. Azure Databricks

Tạo một Azure Databricks Workspace



Workspace "DBS-WORKSPACE-MOVIES" là nơi chạy các notebook và job xử lý dữ liệu. Chúng ta sẽ cấu hình cluster và kết nối tới Data Lake Storage Gen 2.

4. Service Principal

Tạo Service Principal và cấp quyền Reader/Contributor cho Databricks tới Storage Account, đảm bảo authentication an toàn khi Spark job truy xuất dữ liệu.

Bronze Layer

```
May 17, 2025 (<1s) 1

container_name = "bronze"
storage_account_name = "storageaccountofmovies"
client_id = "01a8c98d-6c5d-45d5-8e61-077de7c4060d"
tenant_id = "40127cd4-45f3-49a3-b05d-315a43a9f033"
client_secret = "KzC8Q~gK6i.IRJRETPmzey_s3-EoW-bSn.cXKaw_"</pre>
```

Silver Layer

```
May 17, 2025 (<1s)

container_name = "silver"

storage_account_name = "storageaccountofmovies"

client_id = "01a8c98d-6c5d-45d5-8e61-077de7c4060d"

tenant_id = "40127cd4-45f3-49a3-b05d-315a43a9f033"

client_secret = "KzC8Q~gK6i.IRJRETPmzey_s3-EoW-bSn.cXKaw_"
```

Gold Layer

```
container_name = "gold"
storage_account_name = "storageaccountofmovies"
client_id = "01a8c98d-6c5d-45d5-8e61-077de7c4060d"
tenant_id = "40127cd4-45f3-49a3-b05d-315a43a9f033"
client_secret = "KzC8Q~gK6i.IRJRETPmzey_s3-EoW-bSn.cXKaw_"
```

PIPELINE XỬ LÝ DỮ LIỆU

- 1. Ingest (Bronze Layer)
- ❖ Xác định khoảng thời gian tuần

Chạy Spark SQL trên bảng weekCollectData để tính ngày đầu tuần (GTE) và ngày cuối tuần (LTE).

```
sparksql = """SELECT

MAX(DATE(DAY_LAST_WEEK)) + INTERVAL 1 day AS GTE,
MAX(DATE(DAY_LAST_WEEK)) + INTERVAL 7 days AS LTE

FROM weekCollectData""

sparkdf = spark.sql(sparksql)
row = sparkdf.select('GTE', 'LTE').collect()[0]
gte = row['GTE']
lte = row['LTE']

▶ (2) Spark Jobs

■ sparkdf: pyspark.sql.dataframe.DataFrame = [GTE: date, LTE: date]
```

- Thu thập dữ liệu
- ➤ Lấy danh sách thể loại (genres)

Gọi endpoint /genre/movie/list để tải về bảng genres và lưu vào /bronze/genres (mode overwrite).

```
wide in the image of the
```

> Lấy phim xu hướng & phim mới

Goi /trending/movie/week/

discover/movie?primary release date.gte=GTE&primary release date.lte=LTE

```
# URLs và headers

url_trend = "https://api.themoviedb.org/3/trending/movie/week?language=en-US"

url_new = f"https://api.themoviedb.org/3/discover/movie?include_adult=true&include_video=false&language=en-US&page=1&primary_release_date.gte={str(gte)}&primary_release_date.lte={str(lte)}&sort_by=popularity.desc"

url_base = "https://api.themoviedb.org/3/movie/"

url_language = "?language=en-US"

headers = {
    "accept": "application/json",
    "Authorization": "Bearer eyJhbGciOiJIUzIINiJ9.
    eyJhdWQiOiI2NjQ1ZTUSMDQSMjYwM2RjZTg1N2QzMjERNjYzZGYyMyIsIm5iZiI6MS43NDY3MDQ1MzU4ODYwMDAyZSs5LCJzdWIiOiI2ODFjOTg5N
    zA3MGMXZWEZNJUZZWM3N2QiLCJzY29wZXMiOlsiYXBpX3JlYWQiXSwidmVyc2lvbiI6MX0.
    rjbLOj3waWpva4HHpVWcm0Ij2-kLCBFl0t3d8FwqhnQ"
}
```

➤ Bổ sung thông tin chi tiết

Với mỗi movie_id, dùng hai endpoint /movie/{id} và /movie/{id}/credits để gắn thêm companies, revenue, budget, runtime, directors.

```
✓ May 17, 2025 (46s)
# Duyệt qua từng movie_id và lấy thông tin
movie_companies_trend = []
movie_revenue_trend = []
movie_budget_trend = []
movie_runtime_trend = []
movie_directors_trend = []
movie_companies_new = []
movie_revenue_new = []
movie_budget_new = []
movie_runtime_new = []
movie_directors_new = []
for movie_id in tqdm(lst_id_trend, desc="Trending movie info"):
   companies, revenue, budget, runtime, directors = get_movie_info(movie_id)
    movie companies trend.append(companies)
    movie_revenue_trend.append(revenue)
    movie_budget_trend.append(budget)
    movie_runtime_trend.append(runtime)
    movie_directors_trend.append(directors)
```

```
for movie_id in tqdm(lst_id_new, desc="New movie info"):
   companies, revenue, budget, runtime, directors = get_movie_info(movie_id)
   movie_companies_new.append(companies)
   movie_revenue_new.append(revenue)
   movie_budget_new.append(budget)
    movie_runtime_new.append(runtime)
    movie_directors_new.append(directors)
# Thêm vào DataFrame
df_trend['production_companies'] = movie_companies_trend
df_trend['revenue'] = movie_revenue_trend
df_trend['budget'] = movie_budget_trend
df_trend['runtime'] = movie_runtime_trend
df_trend['directors'] = movie_directors_trend
df_new['production_companies'] = movie_companies_new
df_new['revenue'] = movie_revenue_new
df_new['budget'] = movie_budget_new
df_new['runtime'] = movie_runtime_new
df_new['directors'] = movie_directors_new
```

Chuyển sang Spark DataFrame

Biến đổi Pandas DataFrame → Spark DataFrame, thêm cột collect_date = GTE (áp dụng kỹ thuật CDC Timestamp)

Ghi vào Bronze Layer & cập nhật lịch

Genres: luu Delta table tại /bronze/genres (mode overwrite).

Movies: ghi hai Delta paths /bronze/DataTrend và /bronze/DataNew (mode append, mergeSchema=true).

```
pathDataTrend = '/mnt/storageaccountofmovies/bronze/DataTrend'
pathDataNew = '/mnt/storageaccountofmovies/bronze/DataNew'

(
    sparkdf_trend
    .write
    .format("delta")
    .option("mergeSchema", "true")
    .mode("append")
    .save(pathDataTrend)
)

(
    sparkdf_new
    .write
    .format("delta")
    .option("mergeSchema", "true")
    .mode("append")
    .save(pathDataTrend)
)
```

Cập nhật tuần: chèn DAY_FIRST_WEEK=GTE, DAY_LAST_WEEK=LTE vào bảng weekCollectData.

2. Transform (Silver Layer)

❖ Stage 1 – Chuẩn hóa & đánh dấu loại dữ liệu

Lấy dữ liệu thô từ bronzeDataTrendCollect và bronzeDataNewCollect.

CAST lại kiểu cột:

- o popularity \rightarrow DECIMAL(18,4)
- o vote average \rightarrow DECIMAL(18,3)
- \circ release date \rightarrow DATE

Thêm cột flag category bằng literal ('T' cho phim xu hướng, 'N' cho phim mới).

```
SQL 🗇 ❖ 🖸 :
► ✓ May 17, 2025 (4s)
   INSERT INTO transformDataTrendCollect_stage_1
   SELECT
     backdrop_path,
     title,
     original_title,
     overview,
     poster_path,
     media_type,
     adult,
     original_language,
     genre_ids,
     CAST(popularity AS DECIMAL(18, 4)),
     CAST(release_date AS DATE),
     CAST(vote_average AS DECIMAL(18, 3)),
     vote_count,
    revenue,
     budget,
     production_companies,
     directors,
     collect_date,
   FROM bronzeDataTrendCollect
   WHERE collect_date > (SELECT MAX(collect_date) FROM transformDataTrendCollect)
▶ ■ _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

```
▶ ✓ May 17, 2025 (3s)
   %sql
  INSERT INTO transformDataNewCollect_stage_1
  SELECT
    backdrop_path,
    id,
    title,
     original_title,
    overview,
     poster_path,
     'Movie',
     adult,
     original_language,
     genre_ids,
     CAST(popularity AS DECIMAL(18, 4)),
     CAST(release_date AS DATE),
     video,
     CAST(vote_average AS DECIMAL(18, 3)),
     vote_count,
    revenue,
  budget,
    runtime,
    production_companies,
    directors,
    collect_date,
   FROM bronzeDataNewCollect
  WHERE collect_date > (SELECT MAX(collect_date) FROM transformDataNewCollect)
▶ (6) Spark Jobs
• sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

❖ Stage 2 – Phân rã mảng (Explode) thành dòng

Dùng explode(genre_ids) tách mỗi phần tử trong mảng genre_ids thành một dòng riêng.

Tương tự với production companies và directors.

```
✓ May 17, 2025 (2s)
   INSERT INTO transformDataTrendCollect_stage_2
   SELECT.
    backdrop_path,
    title,
    original_title,
    overview,
    poster_path,
    media_type,
    adult.
    original_language,
    explode(genre_ids),
    popularity,
    release_date,
    video.
    vote_average,
    vote_count,
    revenue,
    budget,
    runtime,
    explode(production_companies),
    explode(directors),
    collect date.
    flag category
   FROM transformDataTrendCollect_stage_1
▶ ■ _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

```
✓ May 17, 2025 (3s)
                                                             12
   INSERT INTO transformDataNewCollect_stage_2
   SELECT
    backdrop_path,
    original_title,
    overview,
    poster_path,
     media_type,
    adult.
     original_language,
     explode(genre_ids),
    popularity,
     release_date,
     video,
     vote_average,
     vote_count,
     revenue.
     budget,
    explode(production_companies),
    explode(directors),
    collect_date,
    flag_category
   FROM transformDataNewCollect_stage_1
• 🔳 _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

❖ Stage 3 – Thêm dữ liệu vào bảng chính

Biến đổi cột production companies thành hai phần company và country.

Chèn dữ liệu vào transformDataTrendCollect và transformDataNewCollect.

```
✓ May 17, 2025 (3s)
                                                             8
  INSERT INTO transformDataTrendCollect
  SELECT
    backdrop_path,
    id,
    title,
    original_title,
    overview,
    poster_path,
    media_type,
    adult,
    original_language,
    genre_ids,
    popularity,
    release_date,
    video,
    vote_average,
    vote_count,
    revenue,
    budget,
     trim(element_at(split(trim(both '{}' from production_companies), ','), 3)),
    trim(element_at(split(trim(both '{}' from production_companies), ','), -1)),
    directors,
     collect_date,
    flag_category
   FROM transformDataTrendCollect_stage_2
▶ ■ _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

```
✓ May 17, 2025 (3s)
                                                            13
   INSERT INTO transformDataNewCollect
    backdrop_path,
    id,
    title,
    original_title,
    overview,
    poster_path,
     media_type,
    adult,
     original_language,
     genre_ids,
     popularity,
     release_date,
     video,
    vote_average,
     vote_count,
     revenue,
     budget,
    trim(element_at(split(trim(both '{}' from production_companies), ','), 3)),
    trim(element_at(split(trim(both '{}' from production_companies), ','), -1)),
    directors,
    collect_date,
    flag_category
   FROM transformDataNewCollect_stage_2
▶ (4) Spark Jobs
• 🔳 _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

Hợp nhất, lọc & tạo Silver Table chính

UNION hai bång transformDataTrendCollect và transformDataNewCollect vào bång tam transformDataAllCollect_stage_1

INSERT INTO transformDataAllCollect

- ✓ Lọc các bản ghi không họp lệ (popularity, vote count, revenue,... \neq 0; country \neq ")
- ✓ Thêm time_inserted và time_updated = current_timestamp()

```
sqL 🗇 ❖ 🖸 :
► ✓ May 17, 2025 (4s)
   INSERT INTO transformDataAllCollect
   SELECT
     backdrop_path,
     id,
     title,
     original_title,
     overview,
     poster_path,
     media_type,
     original_language,
     genre_ids,
     popularity,
      release_date,
     video,
     vote_average,
     vote_count,
     revenue,
     budget,
     runtime,
     company,
     directors,
     collect date.
     flag_category,
     current_timestamp(),
     current_timestamp()
    FROM transformDataAllCollect_stage_1
   WHERE
       popularity <> 0.000
     AND vote_average <> 0.000
     AND vote_count <> 0
     AND revenue \iff 0
     AND budget <> 0
     AND runtime <> 0
     AND country <> "
▶ (4) Spark Jobs
_ sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

3. Load (Gold Layer)

- ❖ Cấu hình các bảng dimensions và bảng fact:
 - **♣** Dim movie

```
%sql
-- tao bang dim_movie
DROP TABLE IF EXISTS dim_movie;
CREATE TABLE IF NOT EXISTS dim_movie (
    movie_id BIGINT,
    title STRING,
    release_date DATE,
    overview STRING,
    time_inserted TIMESTAMP,
    time_updated TIMESTAMP
)
USING DELTA
LOCATION '/mnt/storageaccountofmovies/gold/dim_movie'
OK
```

Dim_genre

Dim company

♣ Dim director

♣ Dim date

♣ Fact movies

```
SQL 🗇 ❖ 🖸 :
May 17, 2025 (2s)
  -- tạo bảng fact_movies
  DROP TABLE IF EXISTS fact_movies;

∨CREATE TABLE IF NOT EXISTS fact_movies (
      movie_id BIGINT,
      genre_id BIGINT,
      company_id BIGINT,
      director_id BIGINT,
      date_id BIGINT,
      popularity DECIMAL(18, 4),
      vote_average DECIMAL(18, 3),
      vote count BIGINT,
      revenue BIGINT,
      budget BIGINT,
      runtime BIGINT,
      flag_category STRING,
      time_inserted TIMESTAMP,
      time_updated TIMESTAMP
  USING DELTA
  LOCATION '/mnt/storageaccountofmovies/gold/fact_movies'
```

- ❖ Load dữ liệu vào các bảng Dimensions cố định (chỉ chạy một lần)
 - Dim genre

• Dim_date (2024/01/01 – 2024/12/31)

Start: ngày bắt đầu tuần, End: ngày kết thúc tuần

- ❖ Load dữ liệu vào các bảng Dimensions còn lại (lập lịch chạy cùng bảng Fact)
- ♣ Stage 1 Chọn bản ghi mới / đã cập nhật
 - Lấy các giá trị DISTINCT từ bảng transformDataAllCollect (title/company/directors).
 - Chỉ chọn những bản ghi có time_updated lớn hơn MAX(time_updated) hiện tại trong bảng dimension (hoặc ngày mặc định 1900-01-01).
 - o Kết quả lưu vào bảng stage 1.

```
% May 17, 2025 (5s) 12

%sq1
CREATE OR REPLACE TABLE dim_director_stage_1 AS
SELECT
DISTINCT directors
FROM transformdataallcollect
WHERE time_updated > (
SELECT IFNULL(MAX(time_updated), TO_DATE('1900-01-01'))
FROM dim_director
)

> (7) Spark Jobs

> (3) Spark Jobs
| Sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

- ♣ Stage 2 So sánh & gán ID tạm
 - LEFT JOIN bảng stage_1 với bảng dimension chính theo key
 (title = title, company = company_name, directors = director_name).
 - O Với mỗi record:
 - Nếu chưa có trong bảng chính → gán ID_tạm = row_number() OVER (...)
 - Nếu đã có → giữ lại ID cũ từ bảng chính.
 - Lưu kết quả vào stage_2.

```
✓ May 17, 2025 (4s)
                                                             3
   CREATE OR REPLACE TABLE dim_movie_stage_2 AS
   SELECT
    CASE WHEN goldDim.title IS NULL
      THEN row_number() OVER (ORDER BY silverDim.title)
      ELSE goldDim.movie_id
    END AS movie_id,
    silverDim.title,
    silverDim.release_date,
    silverDim.overview,
    goldDim.title AS gold_title
   FROM dim_movie_stage_1 silverDim
   LEFT OUTER JOIN dim_movie goldDim
   ON silverDim.title = goldDim.title
   WHERE goldDim.title IS NULL
    OR silverDim.release_date <> goldDim.release_date
    OR silverDim.overview <> goldDim.overview
▶ ■ _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

```
✓ May 17, 2025 (5s)
   %sal
   CREATE OR REPLACE TABLE dim_company_stage_2 AS
    CASE WHEN goldDim.company_name IS NULL
      THEN row number() OVER (ORDER BY silverDim.company)
      ELSE goldDim.company_id
     END AS company_id,
    silverDim.company.
    silverDim.country,
     goldDim.company_name AS gold_company
   FROM dim_company_stage_1 silverDim
   LEFT OUTER JOIN dim_company goldDim
   ON silverDim.company = goldDim.company_name
   WHERE goldDim.company_name IS NULL
   OR silverDim.country <> goldDim.country
• 🔳 _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

- ♣ Stage 3 Tính ID cuối (surrogate key)
 - o CROSS JOIN với truy vấn lấy MAX(id) hiện tại từ bảng dimension chính.
 - Với record mới (không khóp), tăng ID_tạm + MAX(id) để tránh trùng.
 - Với record cũ, giữ nguyên ID cũ.
 - o Kết quả lưu vào stage 3.

```
✓ May 17, 2025 (4s)
  %sal
   CREATE OR REPLACE TABLE dim_company_stage_3 AS
  SELECT
    CASE WHEN gold_company IS NULL
      THEN company_id + MAX_COMPANY
      ELSE company_id
    END AS company_id,
    company,
    country
  FROM dim_company_stage_2
   CROSS JOIN (
    SELECT IFNULL(MAX(company_id), 0) AS MAX_COMPANY
    FROM dim_company
▶ (7) Spark Jobs
▶ ■ _sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

```
May 17, 2025 (4s)

%sql

CREATE OR REPLACE TABLE dim_director_stage_3 AS

SELECT
    director_id + MAX_DIRECTOR AS director_id,
    directors

FROM dim_director_stage_2

CROSS JOIN (
    SELECT IFNULL(MAX(director_id), 0) AS MAX_DIRECTOR
    FROM dim_director
    )

> (7) Spark Jobs

> (7) Spark Jobs

> al4
```

- ♣ Stage 4 MERGE (update/insert) vào bảng dimension
 - o Cú pháp MERGE INTO dim ... USING stage 3 ON key:
 - WHEN MATCHED → UPDATE các cột
 (country, release_date, overview, time_updated = current_timestamp())
 - WHEN NOT MATCHED → INSERT toàn bộ cột
 bao gồm surrogate key, fields, time_inserted = current_timestamp(),
 time updated = current_timestamp().

```
✓ May 17, 2025 (3s)
   %sql
   MERGE INTO dim_movie goldDim
   USING dim_movie_stage_3 silverDim
   ON goldDim.title = silverDim.title
   WHEN MATCHED THEN
    UPDATE SET
      goldDim.release_date = silverDim.release_date,
       goldDim.overview = silverDim.overview,
       goldDim.time_updated = current_timestamp()
   WHEN NOT MATCHED THEN
     INSERT (
       movie_id,
       title,
       release_date,
       overview,
       time_inserted,
       time_updated
       VALUES (
        silverDim.movie_id,
         silverDim.title,
         silverDim.release_date,
        silverDim.overview,
        current_timestamp(),
         current_timestamp()
▶ (6) Spark Jobs
▼ 🗏 _sqldf: pyspark.sql.dataframe.DataFrame
```

```
► ✓ May 17, 2025 (3s)
                                                                                                  SQL 🗇 ❖ [] :
  MERGE INTO dim_company goldDim
  USING dim_company_stage_3 silverDim
  ON goldDim.company_name = silverDim.company
  WHEN MATCHED THEN
    UPDATE SET
     goldDim.country = silverDim.country,
      goldDim.time_updated = current_timestamp()
   WHEN NOT MATCHED THEN
    INSERT (
      company_id,
      company_name,
      country,
      time_inserted,
      time_updated
    VALUES (
     silverDim.company_id,
      silverDim.company,
      silverDim.country,
      current_timestamp(),
      current_timestamp()
▶ (6) Spark Jobs
• sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_updated_rows: long ... 2 more fields]
```

Bảng Dim_director không có cột bổ sung thông tin cho cột directors nên không cần dùng MERGE INTO

```
May 17, 2025 (3s)

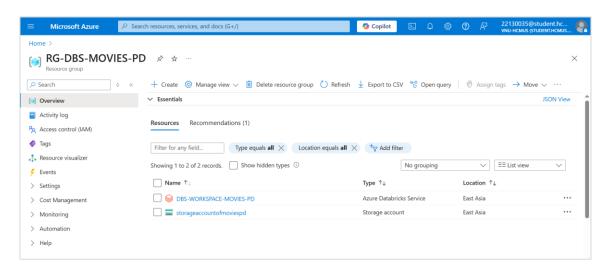
%sql
INSERT INTO dim_director
SELECT
    director_id,
    directors,
    current_timestamp() AS time_inserted,
    current_timestamp() AS time_updated
FROM dim_director_stage_3

> (4) Spark Jobs
    sqldf: pyspark.sql.dataframe.DataFrame = [num_affected_rows: long, num_inserted_rows: long]
```

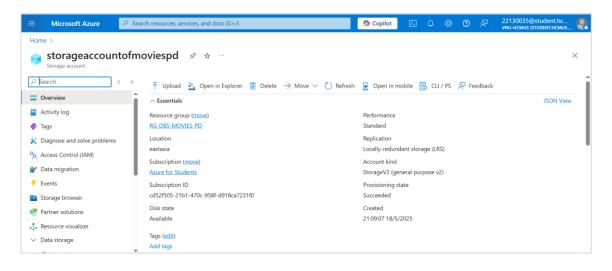
CI/CD VÀ TỰ ĐỘNG HÓA

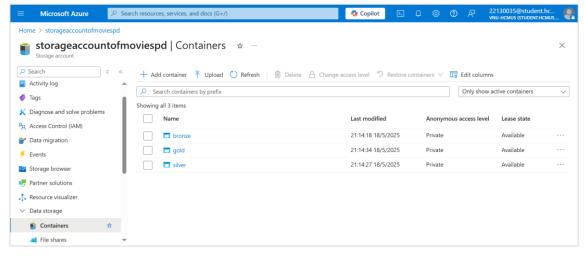
1. Chuẩn bị hạ tầng Production

* Resource Group

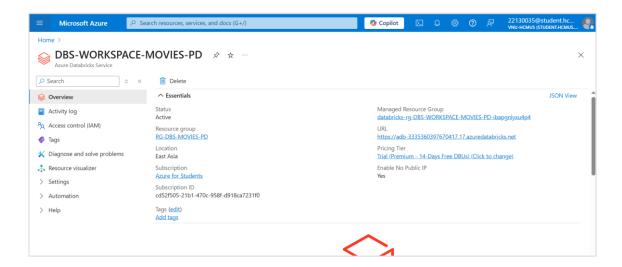


Storage Account

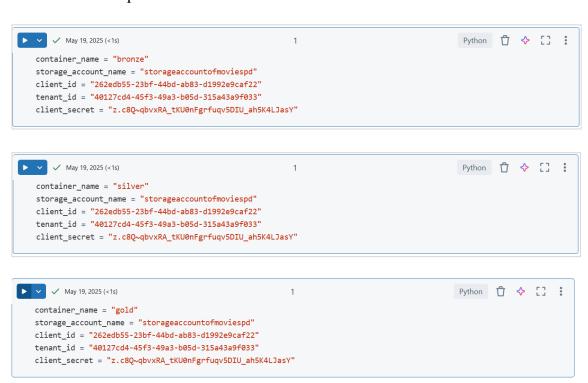




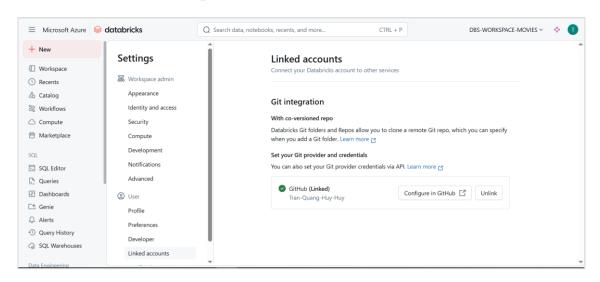
* Azure Databricks

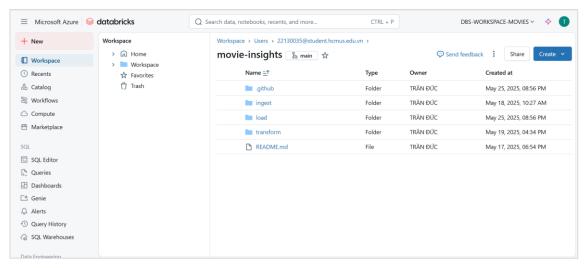


❖ Service Principle

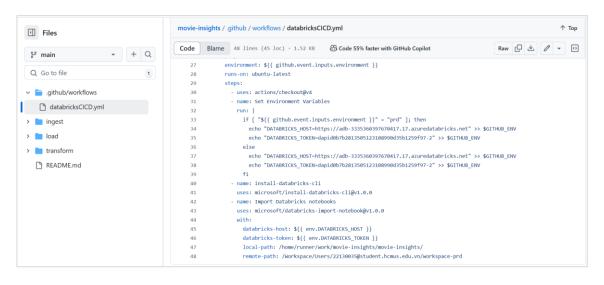


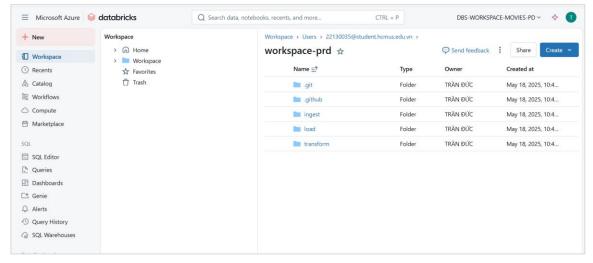
2. Kết nối Git với Workspace Dev



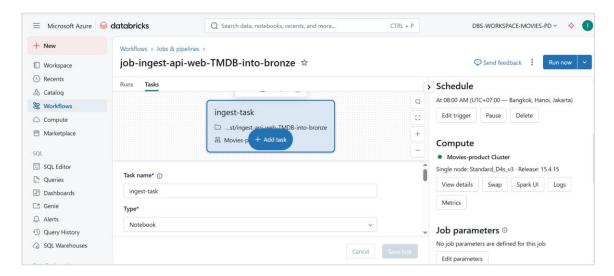


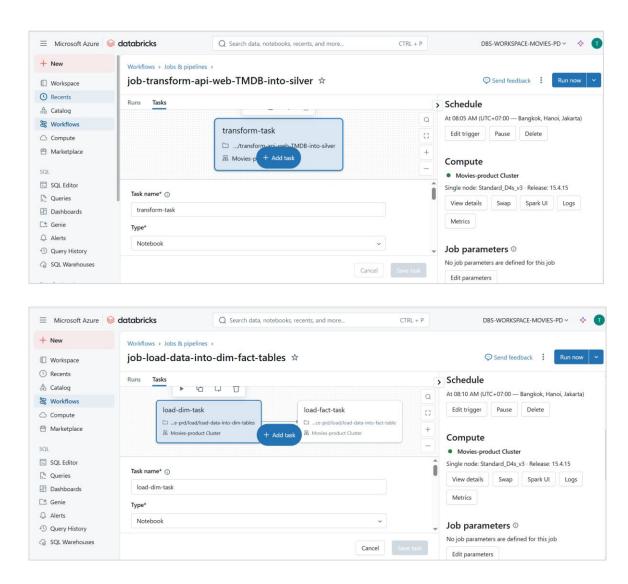
3. Thiết lập CI/CD Production





4. Tự động hóa Lịch Chạy Job





5. Kết nối Power BI với Azure Databricks